Statistique Exploratoire Multidimensionnelle — TP 1

Joshua MAAT

Table des matières

Partie 1 — Quiz **1**
Q1 : réponse 4 . . . 1
Q2 : réponse 2 . . . 1
Q3 : réponse 1 . . . 1
Q4 : réponse 3 . . . 1
Q5 : réponse 4 . . . 1
Q6 : réponse 4 . . . 2
Q7 : réponse 2 . . . 2
Q8 : réponse 4 . . . 2
Q9 : réponse 1 . . . 2
Q10 :réponse 4 (calcul la médiane du vecteur d) . . . 2

Partie 2 — Initiation à R **2**

Partie 1 — Quiz

Q1 : réponse 4

Q2 : réponse 2

Q3 : réponse 1

Q4 : réponse 3

Ce n'est pas la 1 car pas de "0" pour les températures Ce n'est pas 2 car la numérotation ne donne pas d'ordre, pas de distance. La réponse 3 est correcte on garde un ordre Ce n'est pas la 4 la moyenne n'a pas de sens pas de vrai distance entre les niveaux.

Q5 : réponse 4

écart type à 0 et moyenne à 1 donc tous les clients on répondu la même chose (1)

Q6 : réponse 4

Q7 : réponse 2

Q8 : réponse 4

Q9 : réponse 1

Q10 :réponse 4 (calcul la médiane du vecteur d)

Partie 2 — Initiation à R

1) On va créer trois vecteurs `a`, `b`, `c` contenant chacun 3 entiers entre 1 et 9, les assembler en une matrice 3×3 où chaque colonne repprésente un vecteur, puis afficher la matrice.

```
a <- c(1, 2, 3)
b <- c(4, 5, 6)
c <- c(7, 8, 9)
M <- cbind(a, b, c)
print(M)
```

```
##      a b c
## [1,] 1 4 7
## [2,] 2 5 8
## [3,] 3 6 9
```

2) On importe le fichier 'Table0.txt' et on change le nom des colonnes, puis on change le nom des lignes avec les données de la colonnes des noms et on supprime cette colonne.

```
Table0 <- read.table("Table0.txt")
colnames(Table0) <- c("Nom", "Age", "Taille", "Poids", "Sexe")
rownames(Table0) <- Table0$Nom
Table0$Nom <- NULL
Table0
```

```
##          Age Taille Poids Sexe
## Alex      25    177    57    F
## Lilly     31    163    69    F
## Mark      23    190    83    M
## Oliver    52    179    75    M
## Martha    76    163    70    F
## Lucas     49    183    83    M
## Caroline  26    164    53    F
```

3) On importe le fichier 'Table1.txt' et on regarde son nombre de ligne et de colonnes, puis on le réimporte en faisant en sorte que la colonne des noms soit utilisé comme noms de lignes

```
Table1 <- read.table("Table1.txt",TRUE)
nrow(Table1)
```

```
## [1] 7
```

```
ncol(Table1)
```

```
## [1] 5
```

```
Table1
```

```
##       Name Age Height Weight Sex
## 1     Alex  25    177     57   F
## 2    Lilly  31    163     69   F
## 3     Mark  23    190     83   M
## 4   Oliver  52    179     75   M
## 5   Martha  76    163     70   F
## 6    Lucas  49    183     83   M
## 7 Caroline  26    164     53   F
```

```
Table1 <- read.table("Table1.txt", header = TRUE, row.names = 1)

Table1
```

```
##          Age Height Weight Sex
## Alex      25    177     57   F
## Lilly     31    163     69   F
## Mark      23    190     83   M
## Oliver    52    179     75   M
## Martha    76    163     70   F
## Lucas     49    183     83   M
## Caroline  26    164     53   F
```

```
str(Table1)
```

```
## 'data.frame':    7 obs. of  4 variables:
##  $ Age   : int  25 31 23 52 76 49 26
##  $ Height: int  177 163 190 179 163 183 164
##  $ Weight: int  57 69 83 75 70 83 53
##  $ Sex   : chr  "F" "F" "M" "M" ...
```

4) On passe au jeu de données 'Cereals.csv'

```
cereals <- read.csv("Cereals.csv")

head(cereals)
```

```
##                 Cereal.name Supplier Cold.or.Hot calories protein fat sodium
## 1                 100%_Bran        N           C       70       4   1    130
## 2          100%_Natural_Bran        Q           C      120       3   5     15
## 3                   All-Bran        K           C       70       4   1    260
## 4 All-Bran_with_Extra_Fiber        K           C       50       4   0    140
## 5             Almond_Delight        R           C      110       2   2    200
## 6   Apple_Cinnamon_Cheerios        G           C      110       2   2    180
##   fiber carbo sugars potass vitamins   rating
## 1  10.0   5.0      6    280       25 68.40297
## 2   2.0   8.0      8    135        0 33.98368
## 3   9.0   7.0      5    320       25 59.42551
## 4  14.0   8.0      0    330       25 93.70491
## 5   1.0  14.0      8     NA       25 34.38484
## 6   1.5  10.5     10     70       25 29.50954
```

```
str(cereals)
```

```
## 'data.frame':    77 obs. of  13 variables:
##  $ Cereal.name: chr  "100%_Bran" "100%_Natural_Bran" "All-Bran" "All-Bran_with_Extra_Fiber" ...
##  $ Supplier   : chr  "N" "Q" "K" "K" ...
##  $ Cold.or.Hot: chr  "C" "C" "C" "C" ...
```

```
##  $ calories   : int  70 120 70 50 110 110 110 130 90 90 ...
##  $ protein    : int  4 3 4 4 2 2 2 3 2 3 ...
##  $ fat        : int  1 5 1 0 2 2 0 2 1 0 ...
##  $ sodium     : int  130 15 260 140 200 180 125 210 200 210 ...
##  $ fiber      : num  10 2 9 14 1 1.5 1 2 4 5 ...
##  $ carbo      : num  5 8 7 8 14 10.5 11 18 15 13 ...
##  $ sugars     : int  6 8 5 0 8 10 14 8 6 5 ...
##  $ potass     : int  280 135 320 330 NA 70 30 100 125 190 ...
##  $ vitamins   : int  25 0 25 25 25 25 25 25 25 25 ...
##  $ rating     : num  68.4 34 59.4 93.7 34.4 ...
```

On a pour chaque type de céréales des données sur ce qu'elles contiennent ainsi que le fournisseur.

a) D'abord on ajoute une variable 'totalcarb' étant la somme de 'sugars' et 'carbo' :

```
cereals$totalcarb <- cereals$carbo + cereals$sugars
head(cereals)
```

```
##                 Cereal.name Supplier Cold.or.Hot calories protein fat sodium
## 1                 100%_Bran        N           C       70       4   1    130
## 2          100%_Natural_Bran        Q           C      120       3   5     15
## 3                   All-Bran        K           C       70       4   1    260
## 4 All-Bran_with_Extra_Fiber        K           C       50       4   0    140
## 5             Almond_Delight        R           C      110       2   2    200
## 6   Apple_Cinnamon_Cheerios        G           C      110       2   2    180
##   fiber carbo sugars potass vitamins   rating totalcarb
## 1  10.0   5.0      6    280       25 68.40297      11.0
## 2   2.0   8.0      8    135        0 33.98368      16.0
## 3   9.0   7.0      5    320       25 59.42551      12.0
## 4  14.0   8.0      0    330       25 93.70491       8.0
## 5   1.0  14.0      8     NA       25 34.38484      22.0
## 6   1.5  10.5     10     70       25 29.50954      20.5
```

b) On veut compter le nombre de céréal 'hot'

```
hot <- subset(cereals, Cold.or.Hot == "H")
nrow(hot)
```

```
## [1] 3
```

Il y en a donc 3.

c) On veut savoir combien de fournisseur sont unique dans nos données :

```
length(unique(cereals$Supplier))
```

```
## [1] 7
```

Il y en donc 7.

d) On prend un sous ensemble contenant uniquement celles du fournisseur 'K' (Kellogs)

```
kelloggs <- subset(cereals, Supplier == "K")
head(kelloggs)
```

```
##                 Cereal.name Supplier Cold.or.Hot calories protein fat sodium
## 3                   All-Bran        K           C       70       4   1    260
```

```
## 4  All-Bran_with_Extra_Fiber        K           C       50       4   0    140
## 7                 Apple_Jacks        K           C      110       2   0    125
## 17                Corn_Flakes        K           C      100       2   0    290
## 18                  Corn_Pops        K           C      110       1   0     90
## 20          Cracklin'_Oat_Bran        K           C      110       3   3    140
##    fiber carbo sugars potass vitamins   rating totalcarb
## 3      9     7      5    320       25 59.42551        12
## 4     14     8      0    330       25 93.70491         8
## 7      1    11     14     30       25 33.17409        25
## 17     1    21      2     35       25 45.86332        23
## 18     1    13     12     20       25 35.78279        25
## 20     4    10      7    160       25 40.44877        17
```

e) On prend un sous ensemble contenant moins de 80 cal et plus de 20 unité de vitamine :

```
calvit <- subset(cereals, calories < 80 & vitamins > 20)
calvit
```

```
##                 Cereal.name Supplier Cold.or.Hot calories protein fat sodium
## 1                 100%_Bran        N           C       70       4   1    130
## 3                  All-Bran        K           C       70       4   1    260
## 4 All-Bran_with_Extra_Fiber        K           C       50       4   0    140
##   fiber carbo sugars potass vitamins   rating totalcarb
## 1    10     5      6    280       25 68.40297        11
## 3     9     7      5    320       25 59.42551        12
## 4    14     8      0    330       25 93.70491         8
```

f) on prend un sous ensemble contennat au moins une unité de sucre et et on conserve seulement 3 variables :

```
unsucre <- subset(cereals, sugars >= 1,select = c(Cereal.name, calories, vitamins))
head(unsucre)
```

```
##               Cereal.name calories vitamins
## 1                100%_Bran       70       25
## 2       100%_Natural_Bran      120        0
## 3                 All-Bran       70       25
## 5           Almond_Delight      110       25
## 6 Apple_Cinnamon_Cheerios      110       25
## 7              Apple_Jacks      110       25
```

g) on sauvegarde un des sous ensembles d'avant :

```
write.csv(unsucre, file = "unsucre.csv", row.names = FALSE)
```

h) on renomme la colonne fournisseur en producteur :

```
names(cereals)[2] <- "producteur"
head(cereals)
```

```
##                 Cereal.name producteur Cold.or.Hot calories protein fat sodium
## 1                 100%_Bran          N           C       70       4   1    130
## 2         100%_Natural_Bran          Q           C      120       3   5     15
## 3                  All-Bran          K           C       70       4   1    260
## 4 All-Bran_with_Extra_Fiber          K           C       50       4   0    140
## 5            Almond_Delight          R           C      110       2   2    200
```

```
## 6   Apple_Cinnamon_Cheerios          G           C      110       2   2    180
##   fiber carbo sugars potass vitamins   rating totalcarb
## 1  10.0   5.0      6    280       25 68.40297      11.0
## 2   2.0   8.0      8    135        0 33.98368      16.0
## 3   9.0   7.0      5    320       25 59.42551      12.0
## 4  14.0   8.0      0    330       25 93.70491       8.0
## 5   1.0  14.0      8     NA       25 34.38484      22.0
## 6   1.5  10.5     10     70       25 29.50954      20.5
```

5) On passe au jeu de données 'islands'

```
data(islands)
length(islands)
```

```
## [1] 48
```

```
str(islands)
```

```
##  Named num [1:48] 11506 5500 16988 2968 16 ...
##  - attr(*, "names")= chr [1:48] "Africa" "Antarctica" "Asia" "Australia" ...
```

```
head(islands)
```

```
##       Africa   Antarctica         Asia    Australia Axel Heiberg       Baffin
##        11506         5500        16988         2968           16          184
```

```
summary(islands)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    12.0    20.5    41.0  1252.7   183.2 16988.0
```

On a les données de superficie de terres (continents et îles)

On utilise d'autres fonctions que summary pour donner la moyenne, médiane, max, min, écart type, les quantiles :

```
mean(islands)
```

```
## [1] 1252.729
```

```
median(islands)
```

```
## [1] 41
```

```
range(islands)
```

```
## [1]    12 16988
```

```
sd(islands)
```

```
## [1] 3371.146
```

```
quantile(islands, probs = c(0,0.25, 0.5, 0.75,1))
```

```
##       0%      25%      50%      75%     100%
##    12.00    20.50    41.00   183.25 16988.00
```

```
quantile(islands, probs = c(0.005,0.95))
```

```
##     0.5%      95%
##   12.235 8481.750
```

(généralement on veut 5% et 95% on remplacerait 0.005 par 0.05)

```r
q_1 <- quantile(islands, probs = c(0.25))
q_2 <- quantile(islands, probs = c(0.75))
q_2-q_1
```

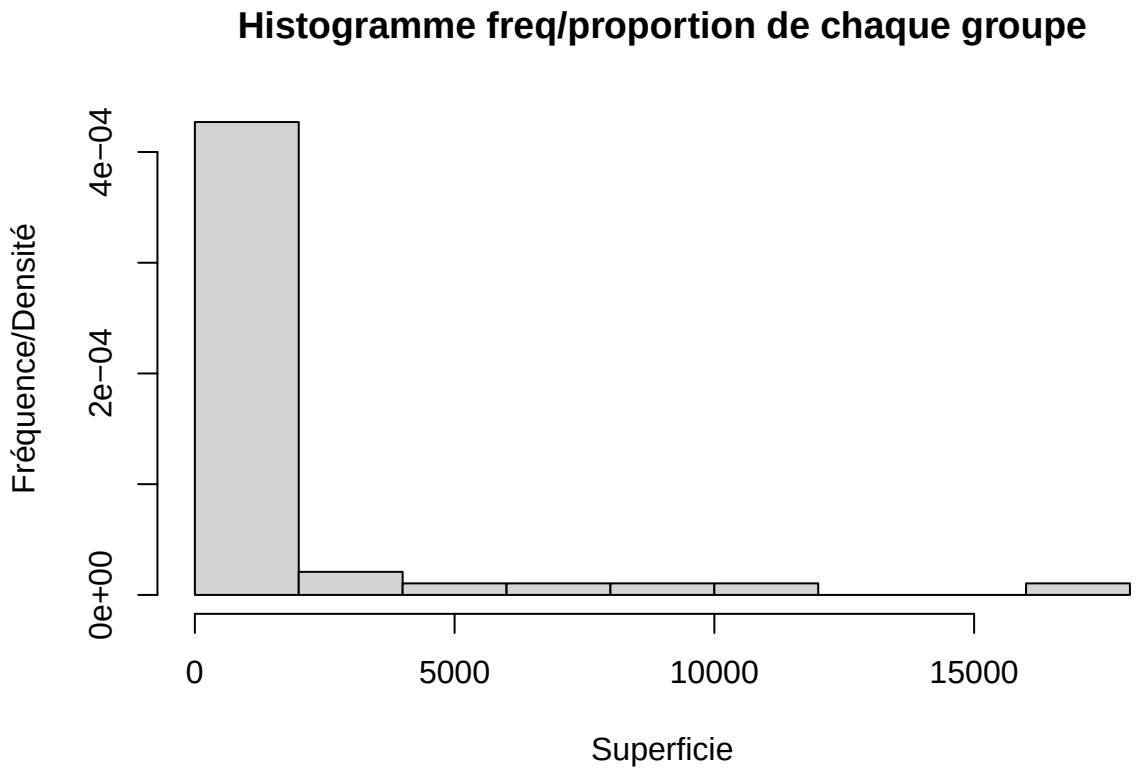
```
##    75%
## 162.75
```

On veut alors créer un histogramme avec certaines propriétés :

– A. Fréquence de chaque groupe

– B. Proportion de chaque groupe

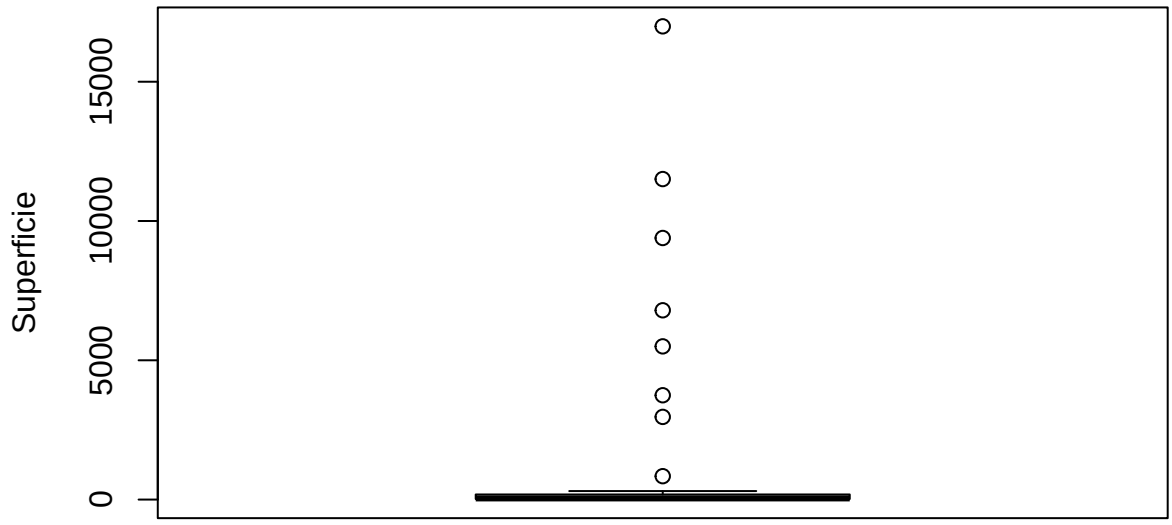
```r
hist(islands,freq = FALSE,main = "Histogramme freq/proportion de chaque groupe",xlab = "Superficie",ylab
```



Et esnuite des diagrammes en boites avec ces conditions :

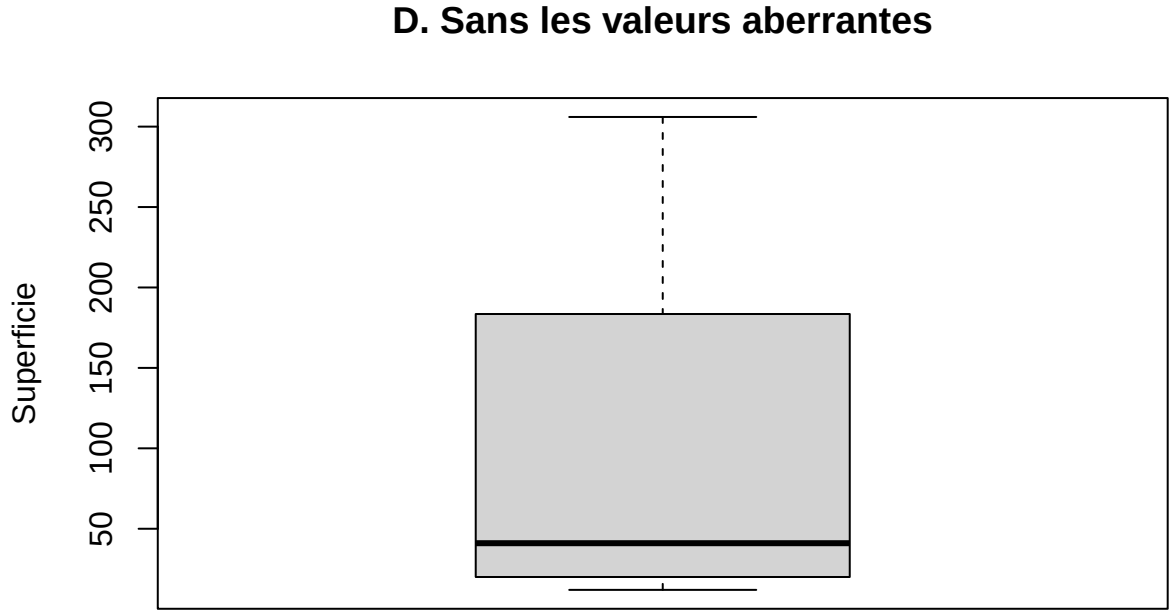
C. Avec les valeurs aberrantes

```r
boxplot(islands,
        main = "C. Avec les valeurs aberrantes",
        ylab = "Superficie")
```



D. Sans les valeurs aberrantes

```
boxplot(islands,
        outline = FALSE,
        main = "D. Sans les valeurs aberrantes",
        ylab = "Superficie")
```



6) On passe au jeu de données 'sales', on veut classer les ventes en trois groupes en fonction du montant des ventes, trois catégories : small, medium, big. On le fait dans une nouvelle catégorie 'spender' :

```
sales <- read.csv("yearly_sales.csv")
head(sales)
```

```
##   cust_id sales_total num_of_orders gender
## 1  100001      800.64             3      F
## 2  100002      217.53             3      F
```

```
## 3  100003       74.58             2      M
## 4  100004      498.60             3      M
## 5  100005      723.11             4      F
## 6  100006       69.43             2      F
```

```
sales$spender <- sales$sales_total
sales$spender <- ifelse(sales$spender < 100, "small",
                 ifelse(sales$spender <= 500, "medium", "big"))
sales$spender <- factor(sales$spender, levels = c("small", "medium", "big"), ordered = TRUE)
head(sales)
```

```
##   cust_id sales_total num_of_orders gender spender
## 1  100001      800.64             3      F     big
## 2  100002      217.53             3      F  medium
## 3  100003       74.58             2      M   small
## 4  100004      498.60             3      M  medium
## 5  100005      723.11             4      F     big
## 6  100006       69.43             2      F   small
```