Statistique Exploratoire Multidimensionnelle — TP 2

Joshua MAAT

Table des matières

1. Représentation tabulaire et graphiques **1**
1) On crée un tableau de contingence avec les frequence absolue (pour cyc et am) : 1
2) On veut alors créer un histogramme avec des fréquence absolues pour l'attribut "wt" en utilisant 5 bins : 2
3) On veut alors faire un diagramme en boite pour l'attribut "poids" : 2

2. Corrélation **3**
1) On veut calculer à la main la corrélation entre a et w : 3
On utilise la fonction de R qui calcul directement pour vérifier : 4
2) On veut cette fois faire la corrélation de rang de Spearman : 4
A la main en code : 4
On utilise la fonction de R qui calcul directement pour vérifier : 4
3) On dessine le nuage de points pour nous rendre compte visuellement de la relation : 4

3. Data Frames **5**
1) On vérifie le type de données que l'on a et vérifions s'il s'agit bien d'un data frame : 5
2) On veut créer un nouvel attribut "states" qui contient le nom des lignes de notre dataset puis enlever le nom des lignes : 6
3) On cherche a trouver combien d'états ont un revenu par habitant supérieur à 4300$ et une population supérieur à 1000 (en millier) habitants : 6
4) On veut maintenant afficher les 5 premiers états aux revenus les plus élevés en ayant trié par ordre décroissant nos données par rapport au revenu : 6
5) On veut créer un nouvel attribut ordinal "frost_cat" prenant des valeurs en fonction d'intervalles des valeurs je suppose de Frost : 7

1. Représentation tabulaire et graphiques

On va utiliser l'ensemble de données intégrées en R "mtcars"

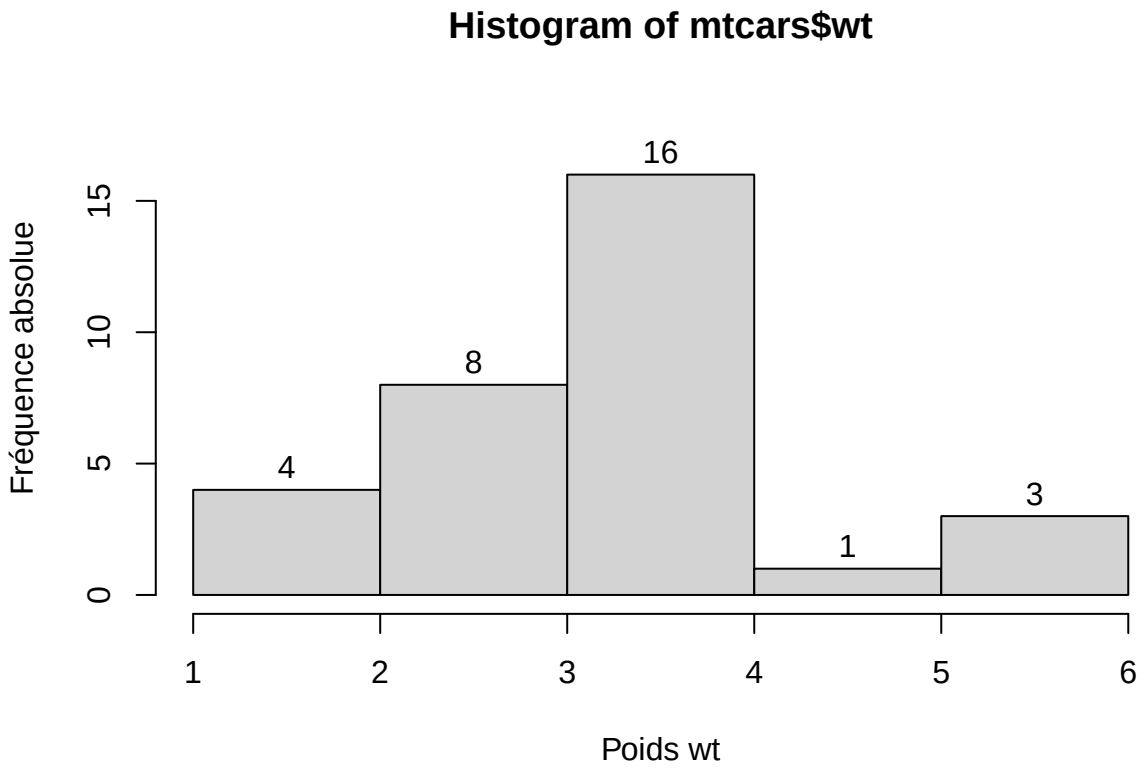
1) On crée un tableau de contingence avec les frequence absolue (pour cyc et am) :

```
t <- table(cyl = mtcars$cyl, am = mtcars$am)
t
```

```
##    am
## cyl  0  1
##   4  3  8
##   6  4  3
##   8 12  2
```

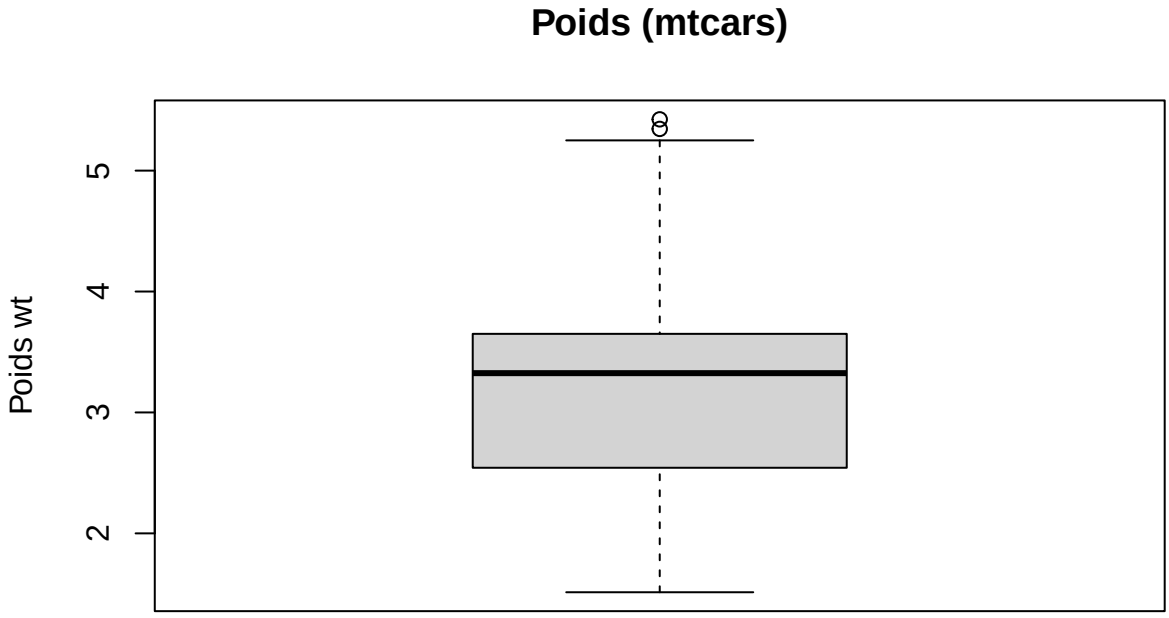
2) On veut alors créer un histogramme avec des fréquence absolues pour l'attribut "wt" en utilisant 5 bins :

```
hist(mtcars$wt,
     breaks = 5,
     freq   = TRUE,
     labels = TRUE,
     ylim   = c(0, 18),
     xlab   = "Poids wt",
     ylab   = "Fréquence absolue")
```



3) On veut alors faire un diagramme en boite pour l'attribut "poids" :

```
boxplot(mtcars$wt,
        main = "Poids (mtcars)",
        ylab = "Poids wt")
```



2. Corrélation

1) On veut calculer à la main la corrélation entre a et w :

$$\bar{a} = \frac{11 + 15 + 23 + 46 + 52 + 75}{6} = \frac{222}{6} = 37$$

$$\bar{w} = \frac{34 + 49 + 58 + 62 + 69 + 64}{6} = \frac{336}{6} = 56$$

$$\sum_{i=1}^{n} (a_i - \bar{a})(w_i - \bar{w}) = 1251$$

$$\sqrt{\sum_{i=1}^{n} (a_i - \bar{a})^2} = \sqrt{3106}$$

$$\sqrt{\sum_{i=1}^{n} (w_i - \bar{w})^2} = \sqrt{806}$$

$$\frac{1251}{\sqrt{3106 \times 806}} \approx 0,79$$

Si on le faisait à la main ça reviendrait au code :

```
a <- c(11, 15, 23, 46, 52, 75)
w <- c(34, 49, 58, 62, 69, 64)
a_bar <- mean(a)
w_bar <- mean(w)
da <- a - a_bar
dw <- w - w_bar
Saw <- sum(da * dw)
Saa <- sum(da^2)
Sww <- sum(dw^2)
```

```
r_pearson <- Saw / sqrt(Saa * Sww)
r_pearson
```

```
## [1] 0.7906587
```

On utilise la fonction de R qui calcul directement pour vérifier :

```
cor(a, w)
```

```
## [1] 0.7906587
```

On voit qu'il y a une assez forte corrélation entre le poids et l'âge.

2) On veut cette fois faire la corrélation de rang de Spearman :

$$1 - \frac{6 \sum_{i=1}^{n} d_i^2}{n\left(n^2 - 1\right)} = 1 - \frac{6 \times 2}{6 \times \left(6^2 - 1\right)} = 1 - \frac{12}{210} = 0,94$$

A la main en code :

```
rang_a <- rank(a)
rang_w <- rank(w)

d <- rang_a - rang_w
sp <- 1 - 6 * sum(d^2) / (6 * (6^2 - 1))
sp
```

```
## [1] 0.9428571
```

On utilise la fonction de R qui calcul directement pour vérifier :

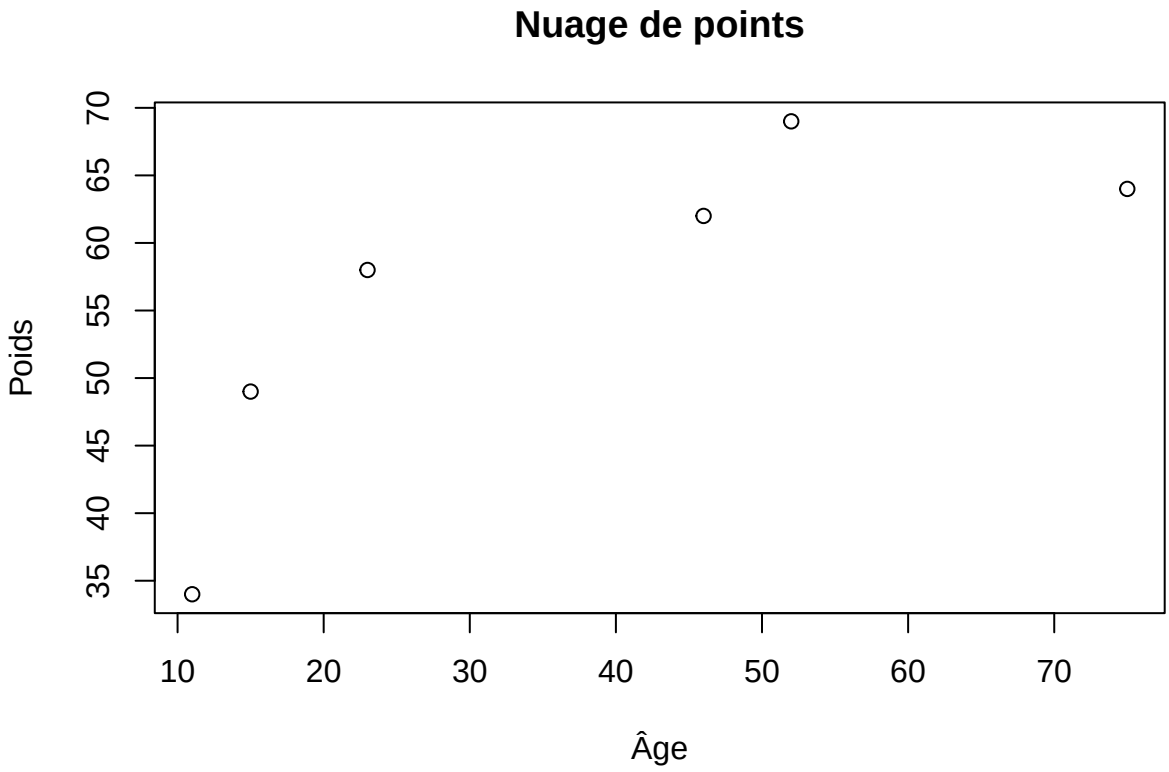
```
cor(a, w, method = "spearman")
```

```
## [1] 0.9428571
```

Que l'on range les personnes par leur age ou par leur poid donnerait quasiment la même chose, on a un résultat très proche de 1.

3) On dessine le nuage de points pour nous rendre compte visuellement de la relation :

```
plot(a, w,
     xlab = "Âge", ylab = "Poids",
     main = "Nuage de points")
```



3. Data Frames

1) On vérifie le type de données que l'on a et vérifions s'il s'agit bien d'un data frame :

```
class(state.x77)
```

```
## [1] "matrix" "array"
```

```
is.data.frame(state.x77)
```

```
## [1] FALSE
```

```
head(state.x77)
```

```
##            Population Income Illiteracy Life Exp Murder HS Grad Frost   Area
## Alabama          3615   3624        2.1    69.05   15.1    41.3    20  50708
## Alaska            365   6315        1.5    69.31   11.3    66.7   152 566432
## Arizona          2212   4530        1.8    70.55    7.8    58.1    15 113417
## Arkansas         2110   3378        1.9    70.66   10.1    39.9    65  51945
## California      21198   5114        1.1    71.71   10.3    62.6    20 156361
## Colorado         2541   4884        0.7    72.06    6.8    63.9   166 103766
```

On le convertit en data frame :

```
state <- as.data.frame(state.x77)
is.data.frame(state)
```

```
## [1] TRUE
```

```
names(state)
```

```
## [1] "Population" "Income"     "Illiteracy" "Life Exp"   "Murder"
## [6] "HS Grad"    "Frost"      "Area"
```

2) On veut créer un nouvel attribut "states" qui contient le nom des lignes de notre dataset puis enlever le nom des lignes :

```
state$states <- rownames(state)
rownames(state) <- NULL
head(state)
```

```
##   Population Income Illiteracy Life Exp Murder HS Grad Frost   Area     states
## 1       3615   3624        2.1    69.05   15.1    41.3    20  50708    Alabama
## 2        365   6315        1.5    69.31   11.3    66.7   152 566432     Alaska
## 3       2212   4530        1.8    70.55    7.8    58.1    15 113417    Arizona
## 4       2110   3378        1.9    70.66   10.1    39.9    65  51945   Arkansas
## 5      21198   5114        1.1    71.71   10.3    62.6    20 156361 California
## 6       2541   4884        0.7    72.06    6.8    63.9   166 103766   Colorado
```

3) On cherche a trouver combien d'états ont un revenu par habitant supérieur à 4300$ et une population supérieur à 1000 (en millier) habitants :

```
revenu_population <- state$Income > 4300 & state$Population > 1000
state$states[revenu_population]
```

```
##  [1] "Arizona"       "California"    "Colorado"      "Connecticut"
##  [5] "Florida"       "Illinois"      "Indiana"       "Iowa"
##  [9] "Kansas"        "Maryland"      "Massachusetts" "Michigan"
## [13] "Minnesota"     "Nebraska"      "New Jersey"    "New York"
## [17] "Ohio"          "Oregon"        "Pennsylvania"  "Virginia"
## [21] "Washington"    "Wisconsin"
```

4) On veut maintenant afficher les 5 premiers états aux revenus les plus élevés en ayant trié par ordre décroissant nos données par rapport au revenu :

```
state_trie <- state[order(state$Income,decreasing = TRUE),]
head(state_trie,5)
```

```
##    Population Income Illiteracy Life Exp Murder HS Grad Frost   Area
## 2         365   6315        1.5    69.31   11.3    66.7   152 566432
## 7        3100   5348        1.1    72.48    3.1    56.0   139   4862
## 20       4122   5299        0.9    70.22    8.5    52.3   101   9891
## 30       7333   5237        1.1    70.93    5.2    52.5   115   7521
## 28        590   5149        0.5    69.03   11.5    65.2   188 109889
##          states
## 2        Alaska
## 7   Connecticut
## 20     Maryland
## 30   New Jersey
## 28       Nevada
```

5) On veut créer un nouvel attribut ordinal "frost_cat" prenant des valeurs en fonction d'intervalles des valeurs je suppose de Frost :

```
state$frost_cat <- cut(state$Frost, breaks = c(-1,30,90,190), labels = c("faible","intermédiaire","élev
state[state$frost_cat == "faible","states"]
```

```
## [1] "Alabama"    "Arizona"    "California" "Florida"    "Hawaii"
## [6] "Louisiana"
```