Statistique Exploratoire Multidimensionnelle — TP 3

Joshua MAAT

Table des matières

1 – Préparaton et calcul de l'APC **1**

2 – Interprétation et visualisation **4**
A) Ces fonctons sont les suivantes : 4
B) Les valeurs propres 4

C) Graphique des variables **6**

D. Cercle de corrélaton (correlaton circle) **7**

E. Qualité de la représentaton **9**

F. Contributons des variables aux composantes principales **12**

G. Graphique des individus **16**

1 – Préparaton et calcul de l'APC

1) Installation et chargement de FactoMinR et FactoExtra

```
install.packages(c("FactoMineR", "factoextra"))
```

```
## Error in contrib.url(repos, "source"): trying to use CRAN without setting a mirror
```

```
library(FactoMineR)
```

```
## Warning: package 'FactoMineR' was built under R version 4.5.2
```

```
library(factoextra)
```

```
## Warning: package 'factoextra' was built under R version 4.5.2
```

```
## Loading required package: ggplot2
```

```
## Welcome to factoextra!
```

```
## Want to learn more? See two factoextra-related books at https://www.datanovia.com/library/principal-
```

2) chargement jeu de données et résumé

```
data(decathlon2, package = "factoextra")
summary(decathlon2)
```

```
##      X100m         Long.jump        Shot.put       High.jump
##  Min.   :10.44   Min.   :6.800   Min.   :12.68   Min.   :1.860
```

```
##  1st Qu.:10.84   1st Qu.:7.210   1st Qu.:14.17   1st Qu.:1.930
##  Median :10.97   Median :7.310   Median :14.57   Median :1.980
##  Mean   :10.99   Mean   :7.365   Mean   :14.54   Mean   :1.998
##  3rd Qu.:11.13   3rd Qu.:7.545   3rd Qu.:15.01   3rd Qu.:2.080
##  Max.   :11.64   Max.   :7.960   Max.   :16.36   Max.   :2.150
##      X400m         X110m.hurdle       Discus        Pole.vault
##  Min.   :46.81   Min.   :13.97   Min.   :37.92   Min.   :4.400
##  1st Qu.:48.70   1st Qu.:14.15   1st Qu.:42.27   1st Qu.:4.660
##  Median :49.20   Median :14.34   Median :44.72   Median :4.900
##  Mean   :49.31   Mean   :14.50   Mean   :44.85   Mean   :4.836
##  3rd Qu.:49.86   3rd Qu.:14.87   3rd Qu.:46.93   3rd Qu.:5.000
##  Max.   :51.16   Max.   :15.67   Max.   :51.65   Max.   :5.400
##     Javeline         X1500m           Rank            Points       Competition
##  Min.   :50.31   Min.   :262.1   Min.   : 1.000   Min.   :7313   Decastar:13
##  1st Qu.:55.32   1st Qu.:271.6   1st Qu.: 4.000   1st Qu.:8000   OlympicG:14
##  Median :57.19   Median :278.1   Median : 7.000   Median :8084
##  Mean   :58.32   Mean   :278.5   Mean   : 7.444   Mean   :8119
##  3rd Qu.:62.05   3rd Qu.:283.6   3rd Qu.:10.500   3rd Qu.:8236
##  Max.   :70.52   Max.   :301.5   Max.   :19.000   Max.   :8893
```

```
dim(decathlon2)
```

```
## [1] 27 13
```

3) On extrait les 10 premières variables du tableau qui correspondent aux sports

```
decatsports <- decathlon2[1:23,1:10]
head(decatsports)
```

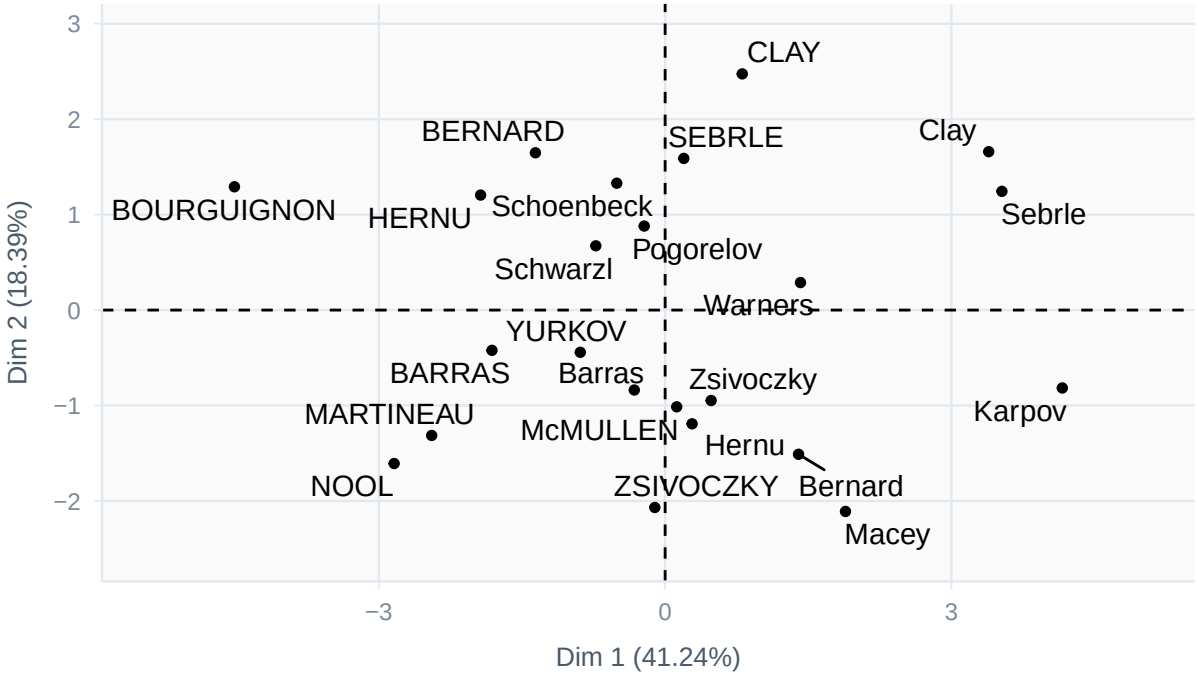
```
##           X100m Long.jump Shot.put High.jump X400m X110m.hurdle Discus
## SEBRLE    11.04      7.58    14.83      2.07 49.81        14.69  43.75
## CLAY      10.76      7.40    14.26      1.86 49.37        14.05  50.72
## BERNARD   11.02      7.23    14.25      1.92 48.93        14.99  40.87
## YURKOV    11.34      7.09    15.19      2.10 50.42        15.31  46.26
## ZSIVOCZKY 11.13      7.30    13.48      2.01 48.62        14.17  45.67
## McMULLEN  10.83      7.31    13.76      2.13 49.91        14.38  44.41
##           Pole.vault Javeline X1500m
## SEBRLE          5.02    63.19  291.7
## CLAY            4.92    60.15  301.5
## BERNARD         5.32    62.77  280.1
## YURKOV          4.72    63.44  276.4
## ZSIVOCZKY       4.42    55.37  268.0
## McMULLEN        4.42    56.37  285.1
```

4) On effectue une acp normée, les paramètres les pus importants sont :

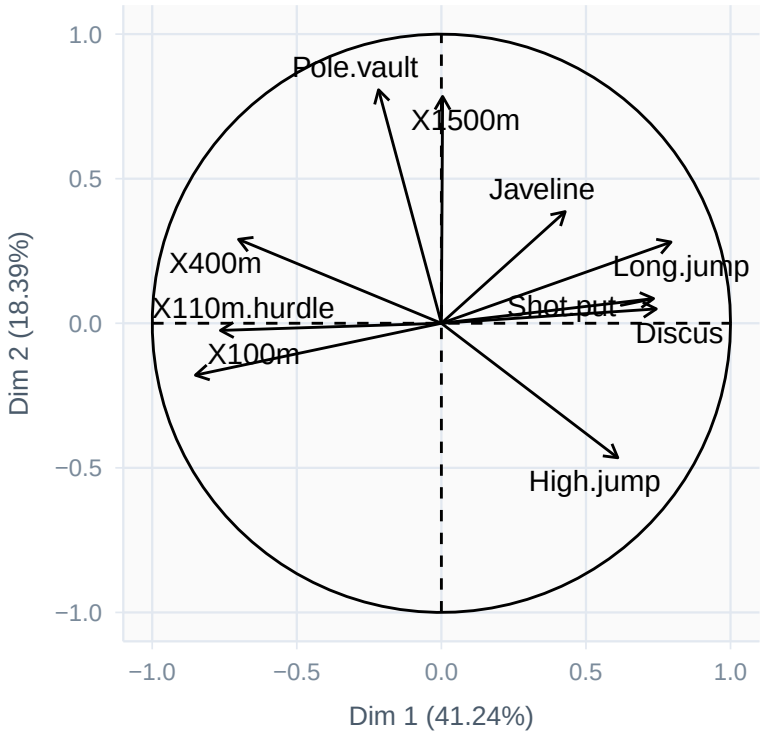
– X le jeu de données – scale.unit (true ou false) pour normaliser les données – ncp (le nombre de composantes principales) – ensuite les .sup qui permettent d'ajouter des individus, ou des variables quantitatives ou qualitatives (elles ne participent pas à la construction des composantes principales) – Le graph pour l'affichage

```
library(FactoMineR)
library(factoextra)
acpdecat <- PCA(decatsports, scale.unit = TRUE)
```

PCA graph of individuals



PCA graph of variables




```
print(acpdecat)
```

```
## **Results for the Principal Component Analysis (PCA)**
## The analysis was performed on 23 individuals, described by 10 variables
## *The results are available in the following objects:
```

```
##
##    name               description
## 1  "$eig"             "eigenvalues"
## 2  "$var"             "results for the variables"
## 3  "$var$coord"       "coord. for the variables"
## 4  "$var$cor"         "correlations variables - dimensions"
## 5  "$var$cos2"        "cos2 for the variables"
## 6  "$var$contrib"     "contributions of the variables"
## 7  "$ind"             "results for the individuals"
## 8  "$ind$coord"       "coord. for the individuals"
## 9  "$ind$cos2"        "cos2 for the individuals"
## 10 "$ind$contrib"     "contributions of the individuals"
## 11 "$call"            "summary statistics"
## 12 "$call$centre"     "mean of the variables"
## 13 "$call$ecart.type" "standard error of the variables"
## 14 "$call$row.w"      "weights for the individuals"
## 15 "$call$col.w"      "weights for the variables"
```

2 – Interprétation et visualisation

Interprétation et utilisations des données fournies par l'acp par des fonctions du package R factoextra

A) Ces fonctons sont les suivantes :

5) on écrit un résumé pour chacune d'elles :

– **get_eigenvalue(res.pca)**

Nous donne les valeurs propres, le pourcentage de variance et le pourcentage cumulé de chaque composante.

– **fviz_eig(res.pca)**

Trace le diagramme des éboulis

– **get_pca_ind(res.pca)**

Extrait les résultats des individus

– **get_pca_var(res.pca)**

Extrait les résultats des variables

– **fviz_pca_ind(res.pca)**

Visualisation du nuage des individus

– **fviz_pca_var(res.pca)**

permet d'afficher le cercle des corrélations des variables

– **fviz_pca_biplot(res.pca)**

Permet de superposer les individus et les variables sur le même graphique

B) Les valeurs propres

On s'intéresse aux valeurs propres, on veut choisir notre nombre de composantes principales.

6) on utilise la fonction get_eigenvalue(res.pca) pour avoir les valeurs propres, la proporton de variance retenue et la proporton cumulatve de variance retenue

```
eig <- get_eigenvalue(acpdecat)
round(eig, 2)
```

```
##       eigenvalue variance.percent cumulative.variance.percent
## Dim.1       4.12            41.24                        41.24
## Dim.2       1.84            18.39                        59.63
## Dim.3       1.24            12.39                        72.02
## Dim.4       0.82             8.19                        80.21
## Dim.5       0.70             7.02                        87.23
```

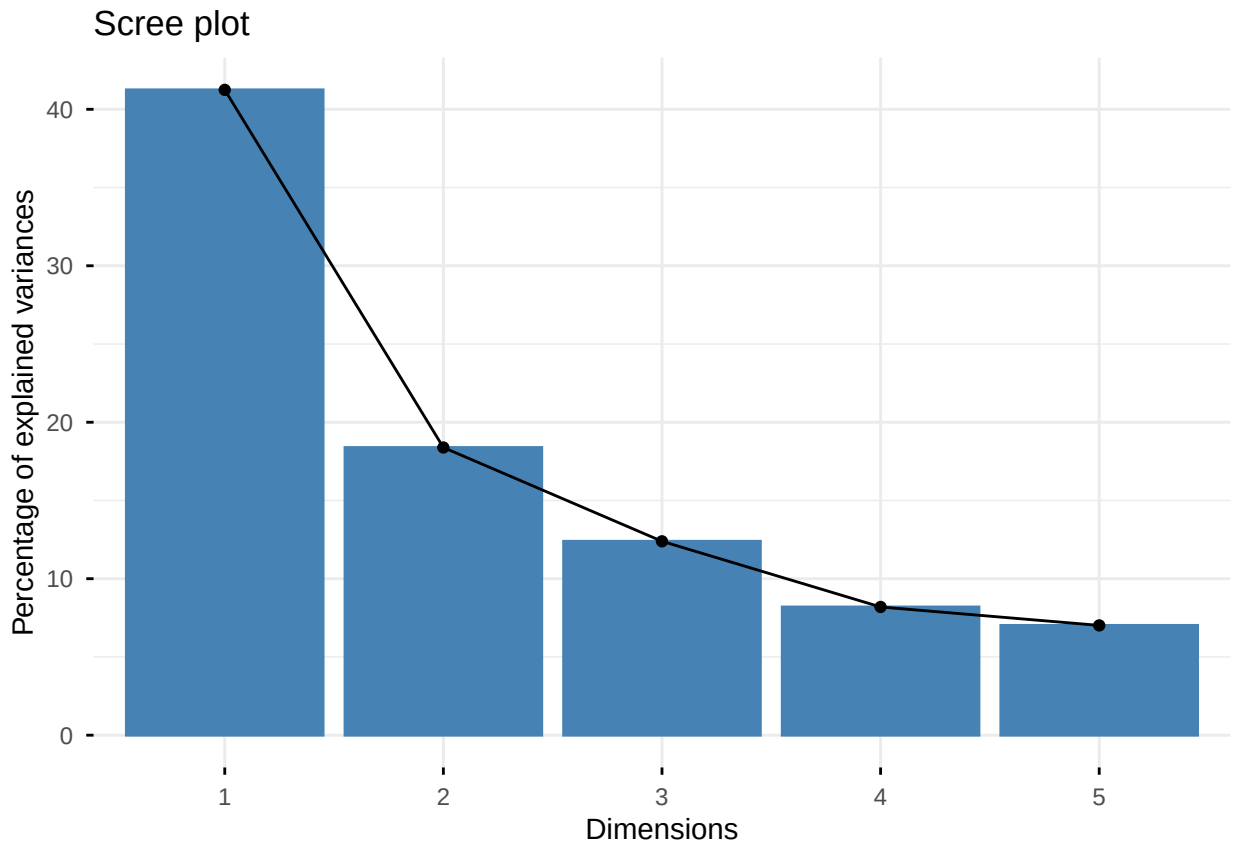
7) La variance retenue par les trois première composantes principales est 72.02%

8) Ayant effectué mon mémoire de l'année dernière sur l'acp je peux dire qu'il n'y a pas de règle absolu tout dépend de ce que l'on souhaite faire, plusieurs règles existent : critère de kaiser, règle du coude... mais pour donner une réponse ici on pourrait considéré que 2 composantes principales sont vraiment insuffisantes.

9) On fait un diagramme de Scree

```
fviz_eig(acpdecat)
```

```
## Warning: This FactoMineR PCA result contains only 5 eigenvalues and does not
## include the complete spectrum. Refit the PCA with a larger `ncp` before drawing
## a complete scree plot.
```



La règle du coude mentionné avant, on peut retenir 3 composantes.

C) Graphique des variables

```
var <- get_pca_var(acpdecat)
var
```

```
## Principal Component Analysis Results for variables
##  ===================================================
##   Name       Description
## 1 "$coord"   "Coordinates for the variables"
## 2 "$cor"     "Correlations between variables and dimensions"
## 3 "$cos2"    "Cos2 for the variables"
## 4 "$contrib" "contributions of the variables"
```

```
head(var$coord)
```

```
##                  Dim.1       Dim.2      Dim.3       Dim.4      Dim.5
## X100m        -0.8506257 -0.17939806  0.3015564  0.03357320 -0.1944440
## Long.jump     0.7941806  0.28085695 -0.1905465 -0.11538956  0.2331567
## Shot.put      0.7339127  0.08540412  0.5175978  0.12846837 -0.2488129
## High.jump     0.6100840 -0.46521415  0.3300852  0.14455012  0.4027002
## X400m        -0.7016034  0.29017826  0.2835329  0.43082552  0.1039085
## X110m.hurdle -0.7641252 -0.02474081  0.4488873 -0.01689589  0.2242200
```

```
head(var$cor)
```

```
##                  Dim.1       Dim.2      Dim.3       Dim.4      Dim.5
## X100m        -0.8506257 -0.17939806  0.3015564  0.03357320 -0.1944440
## Long.jump     0.7941806  0.28085695 -0.1905465 -0.11538956  0.2331567
## Shot.put      0.7339127  0.08540412  0.5175978  0.12846837 -0.2488129
## High.jump     0.6100840 -0.46521415  0.3300852  0.14455012  0.4027002
## X400m        -0.7016034  0.29017826  0.2835329  0.43082552  0.1039085
## X110m.hurdle -0.7641252 -0.02474081  0.4488873 -0.01689589  0.2242200
```

```
head(var$cos2)
```

```
##                  Dim.1        Dim.2      Dim.3        Dim.4      Dim.5
## X100m        0.7235641 0.0321836641 0.09093628 0.0011271597 0.03780845
## Long.jump    0.6307229 0.0788806285 0.03630798 0.0133147506 0.05436203
## Shot.put     0.5386279 0.0072938636 0.26790749 0.0165041211 0.06190783
## High.jump    0.3722025 0.2164242070 0.10895622 0.0208947375 0.16216747
## X400m        0.4922473 0.0842034209 0.08039091 0.1856106269 0.01079698
## X110m.hurdle 0.5838873 0.0006121077 0.20149984 0.0002854712 0.05027463
```

```
head(var$contrib)
```

```
##                  Dim.1      Dim.2     Dim.3       Dim.4     Dim.5
## X100m        17.544293  1.7505098  7.338659  0.13755240  5.389252
## Long.jump    15.293168  4.2904162  2.930094  1.62485936  7.748815
## Shot.put     13.060137  0.3967224 21.620432  2.01407269  8.824401
## High.jump     9.024811 11.7715838  8.792888  2.54987951 23.115504
## X400m        11.935544  4.5799296  6.487636 22.65090599  1.539012
## X110m.hurdle 14.157544  0.0332933 16.261261  0.03483735  7.166193
```

var$coord contient les coordonnées des variables sur chaque axe

var$cor contient les corrélations entre chaque variable et chaque composante principale

var$cos2 contient les cosinus carrés, c'est-à-dire la qualité de représentation de chaque variable sur chaque axe

var$contrib contient les contributions de chaque variable à la construction de chaque axe

D. Cercle de corrélaton (correlaton circle)

11) Le cercle des corrélations est la représentation graphique des variables dans le plan des deux premiers facteurs (F1,F2)

Règles d'interprétation :

— Un point proche du bord du cercle indique que la variable est bien représentée sur le plan (F1,F2).

— Deux variables proches l'une de l'autre sont fortement et positivement corrélées; à l'opposé, elles sont fortement négativement corrélées.

— Une variable proche du centre est mal représentée sur ce plan (son information est portée par d'autres axes).

— L'angle θ entre les vecteurs de deux variables approche leur corrélation :$r(xj, xm) \approx \cos(\theta)$

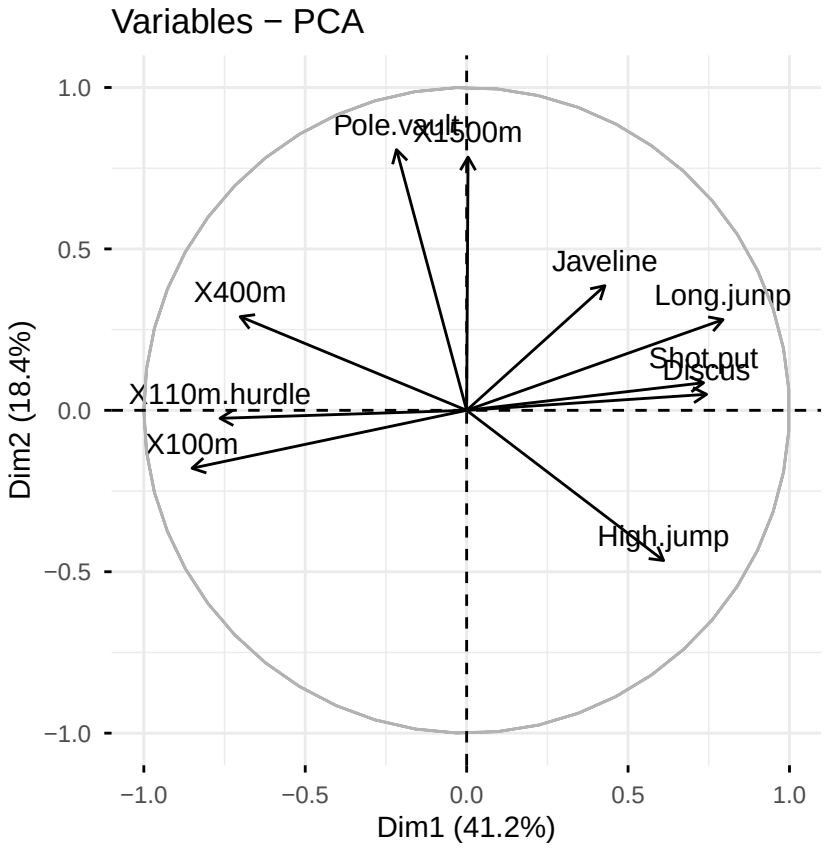
12) on trouve les données avec :

```
head(var$coord)
```

```
##                   Dim.1       Dim.2      Dim.3       Dim.4      Dim.5
## X100m        -0.8506257 -0.17939806  0.3015564  0.03357320 -0.1944440
## Long.jump     0.7941806  0.28085695 -0.1905465 -0.11538956  0.2331567
## Shot.put      0.7339127  0.08540412  0.5175978  0.12846837 -0.2488129
## High.jump     0.6100840 -0.46521415  0.3300852  0.14455012  0.4027002
## X400m        -0.7016034  0.29017826  0.2835329  0.43082552  0.1039085
## X110m.hurdle -0.7641252 -0.02474081  0.4488873 -0.01689589  0.2242200
```

13) On le construit avec :

```
fviz_pca_var(acpdecat)
```



14) Dim.1 (41.2 %) oppose les épreuves de vitesse aux épreuves de puissance et de saut.

X100m (-0.85),

X110m.hurdle (-0.76),

X400m (-0.70)

ont des corrélations négatives.

Long.jump (0.79),

Discus (0.74),

Shot.put (0.73),

High.jump (0.61)

ont des corrélations positives.

Dim.2 (18.4 %) est surtout portée par Pole.vault (0.81) et X1500m (0.78), qui sont les deux variables les plus proches de cet axe.

X100m, X400m et X110m.hurdle pointent dans la même direction, donc elles sont corrélées positivement entre elles.

Elles sont opposées à Long.jump, Shot.put et Discus (corrélation négative).

E. Qualité de la représentaton

15) La qualité de représentation d'une variable sur un axe mesure à quel point cette variable est bien reconstituée par cet axe. Elle se calcule par le cosinus carré de l'angle entre la variable et l'axe.

Proche de 1 est bien représentée dans le sous espace choisi.

À l'inverse, proche de 0 signale que la variable est mal représentée et que son information est portée par d'autres axes.

16) On s'interesse à la fonction corrplot :

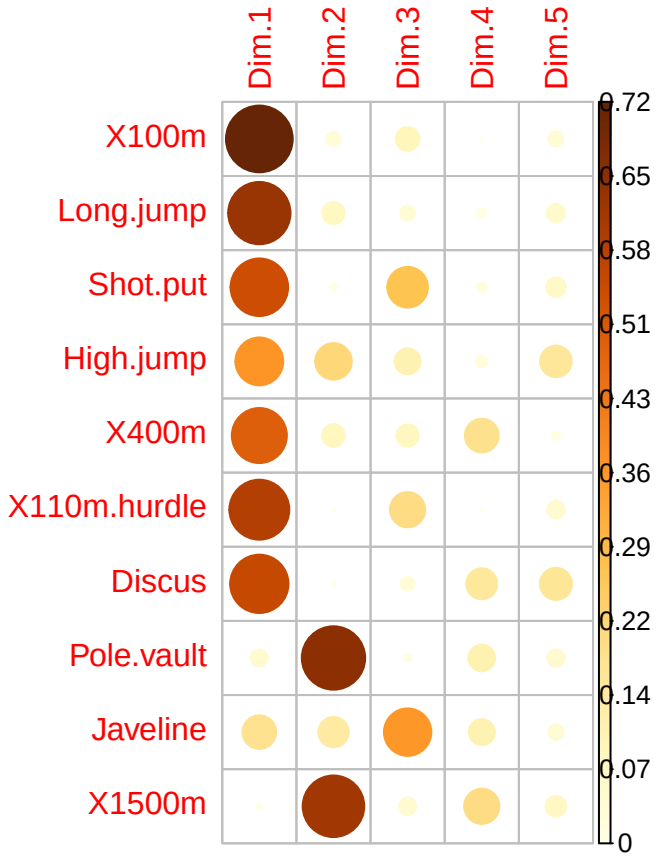
```
library(corrplot)
```

```
## corrplot 0.95 loaded
```

corr : la matrice à afficher. is.corr : TRUE si c'est une matrice de corrélations (valeurs entre -1 et 1). Pour cos2 ou contrib, on met FALSE. method : la forme ("circle" par défaut, "square", "number", "color"...). type : matrice complète, partie haute ou basse. col : la palette de couleurs. tl.col, tl.cex : couleur et taille des noms.

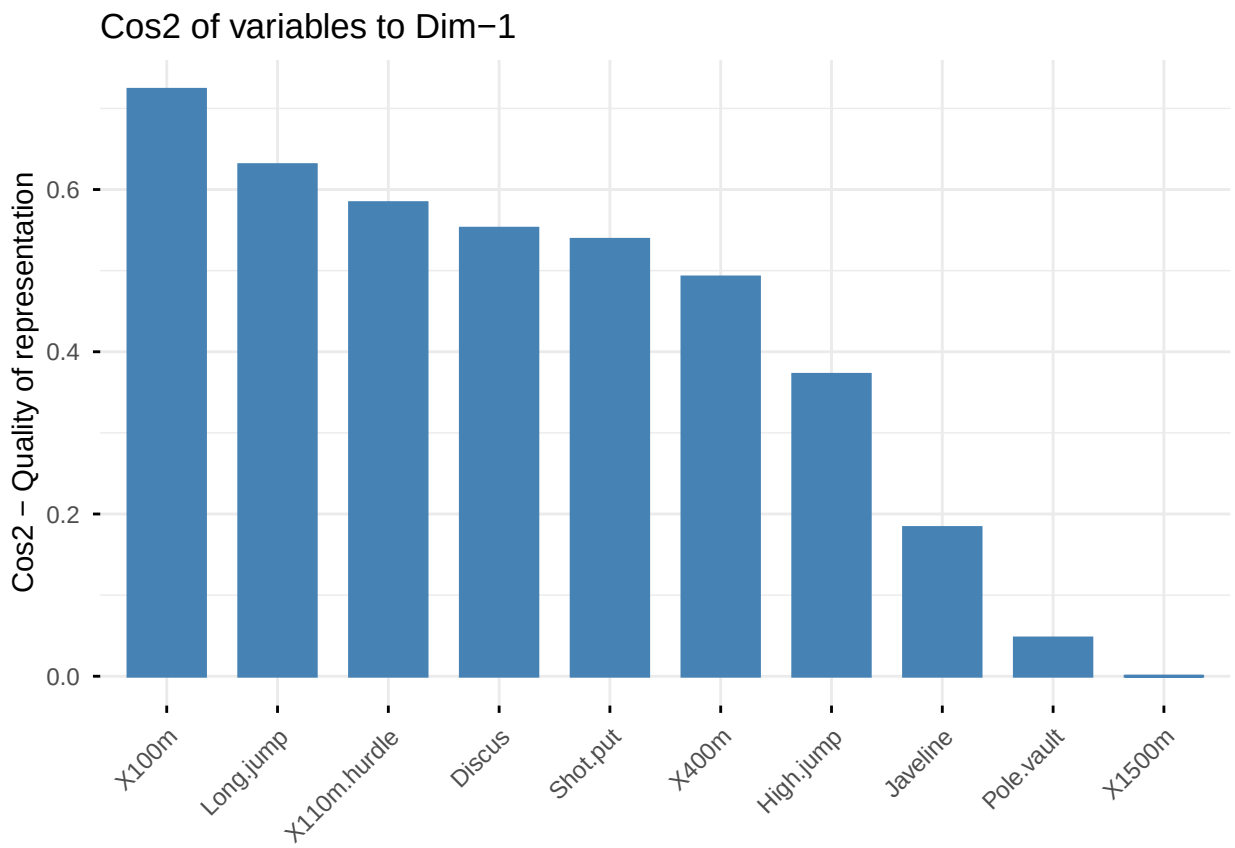
17) On visualise

```
corrplot(var$cos2, is.corr = FALSE)
```

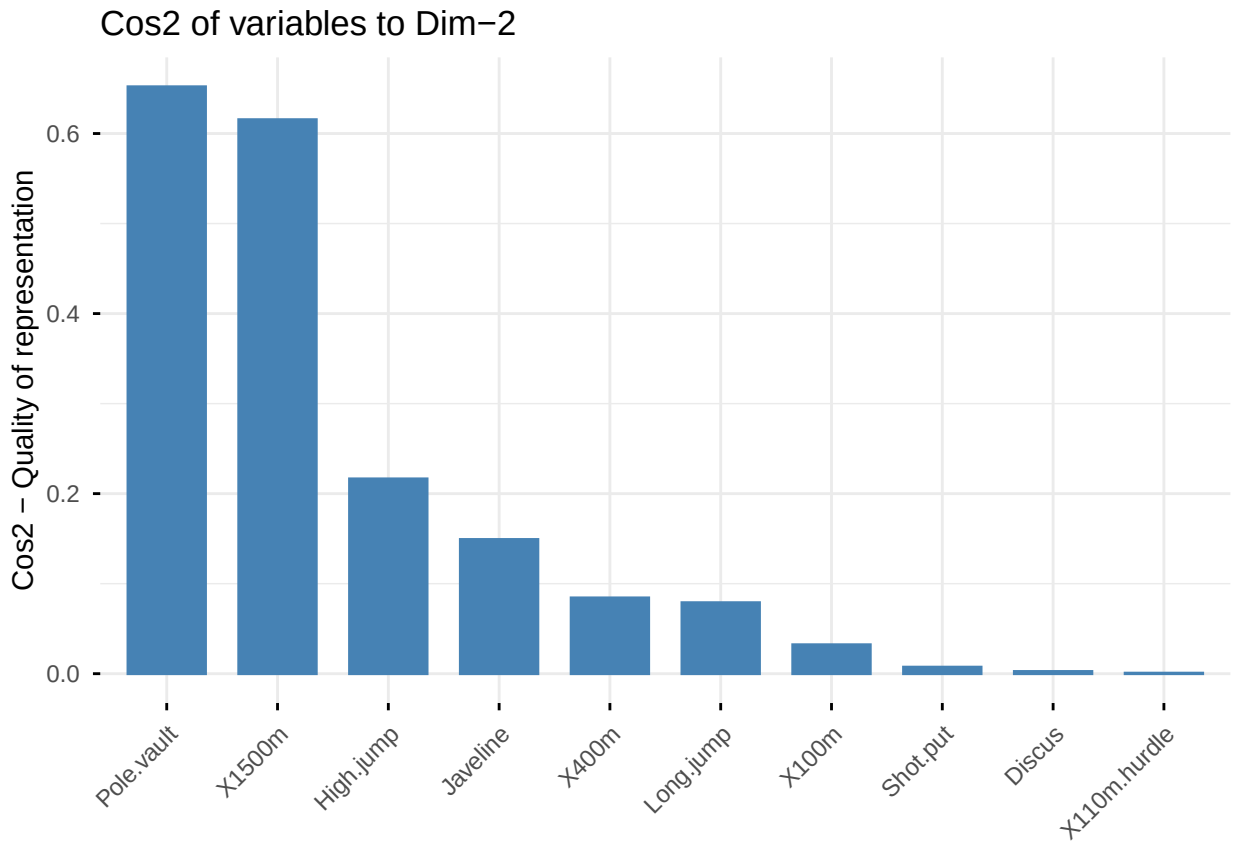


18) On crée le diagramme en barre :

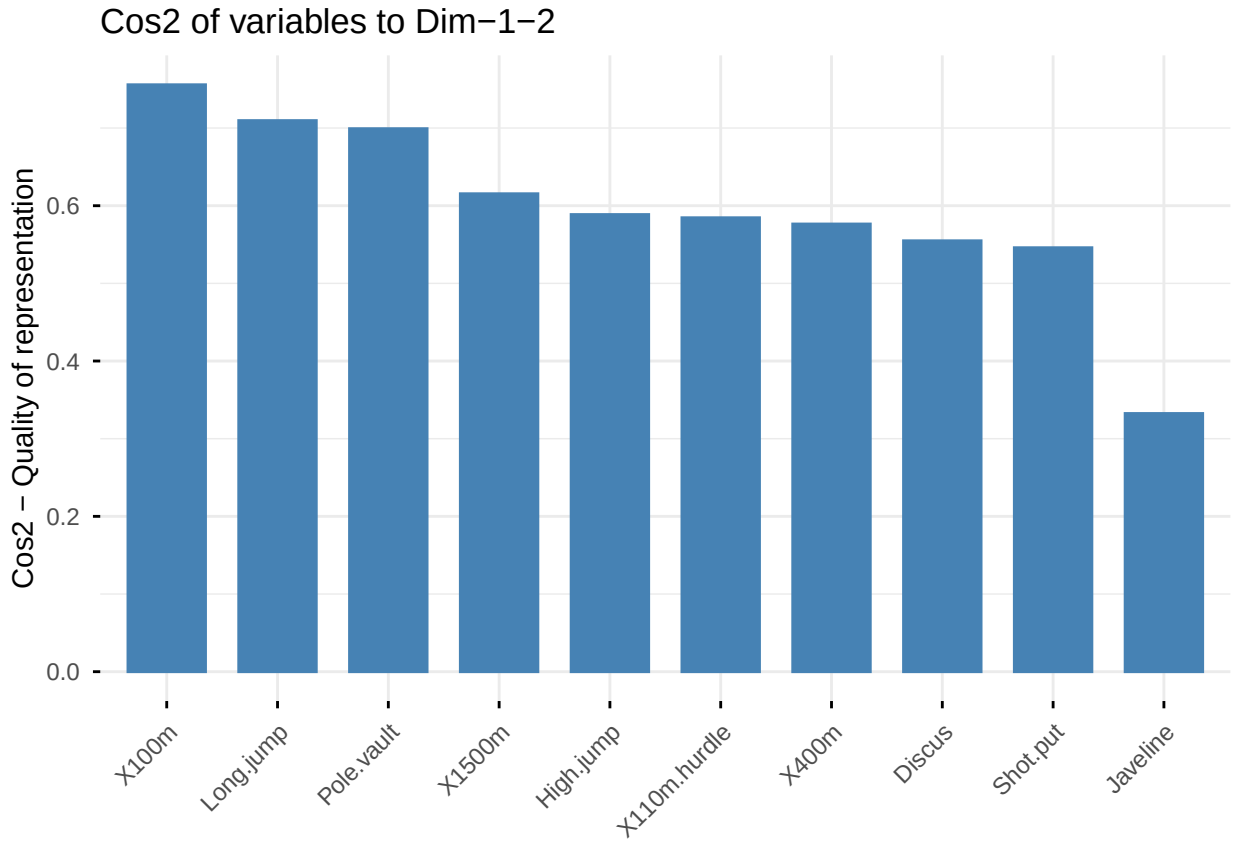
```
fviz_cos2(acpdecat, choice = "var", axes = 1)
```




```
fviz_cos2(acpdecat, choice = "var", axes = 2)
```




```
fviz_cos2(acpdecat, choice = "var", axes = 1:2)
```



19) On interprete :

Sur Dim.1, les variables les mieux représentées sont X100m, Long.jum, X110m.hurdle, Discus et Shot.put.

Sur Dim.2, Pole.vault et X1500m sont les mieux représentées. Les autres variables ont des cos2 faibles sur cet axe.

Sur le plan 1-2, les cos2 cumulés vont de 0.33 à 0.76. X100m, Long.jump et Pole.vault sont bien représentées.

Javeline est mal représentée sur ce plan.

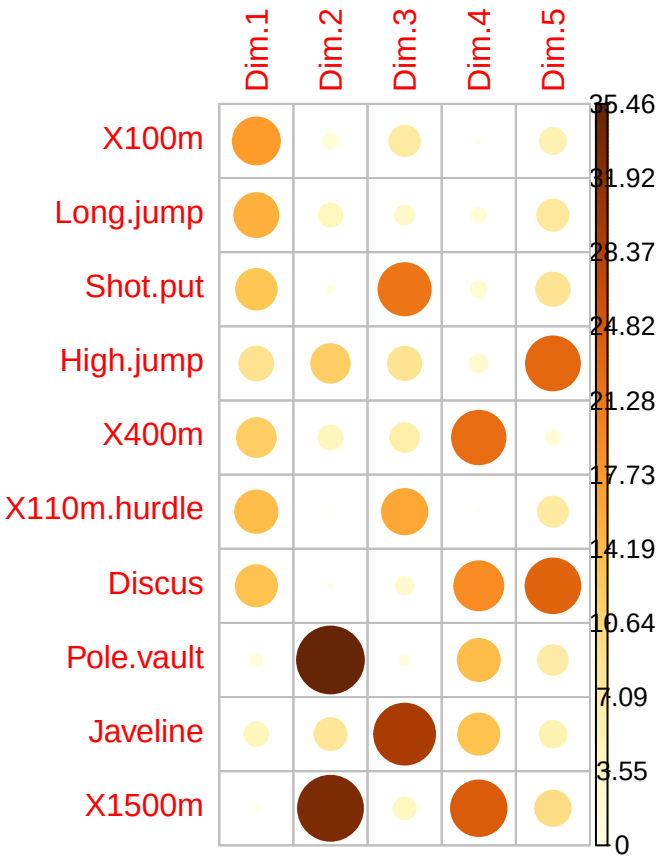
F. Contributons des variables aux composantes principales

```
head(var$contrib, 4)
```

```
##               Dim.1      Dim.2     Dim.3     Dim.4     Dim.5
## X100m     17.544293  1.7505098  7.338659 0.1375524  5.389252
## Long.jump 15.293168  4.2904162  2.930094 1.6248594  7.748815
## Shot.put  13.060137  0.3967224 21.620432 2.0140727  8.824401
## High.jump  9.024811 11.7715838  8.792888 2.5498795 23.115504
```

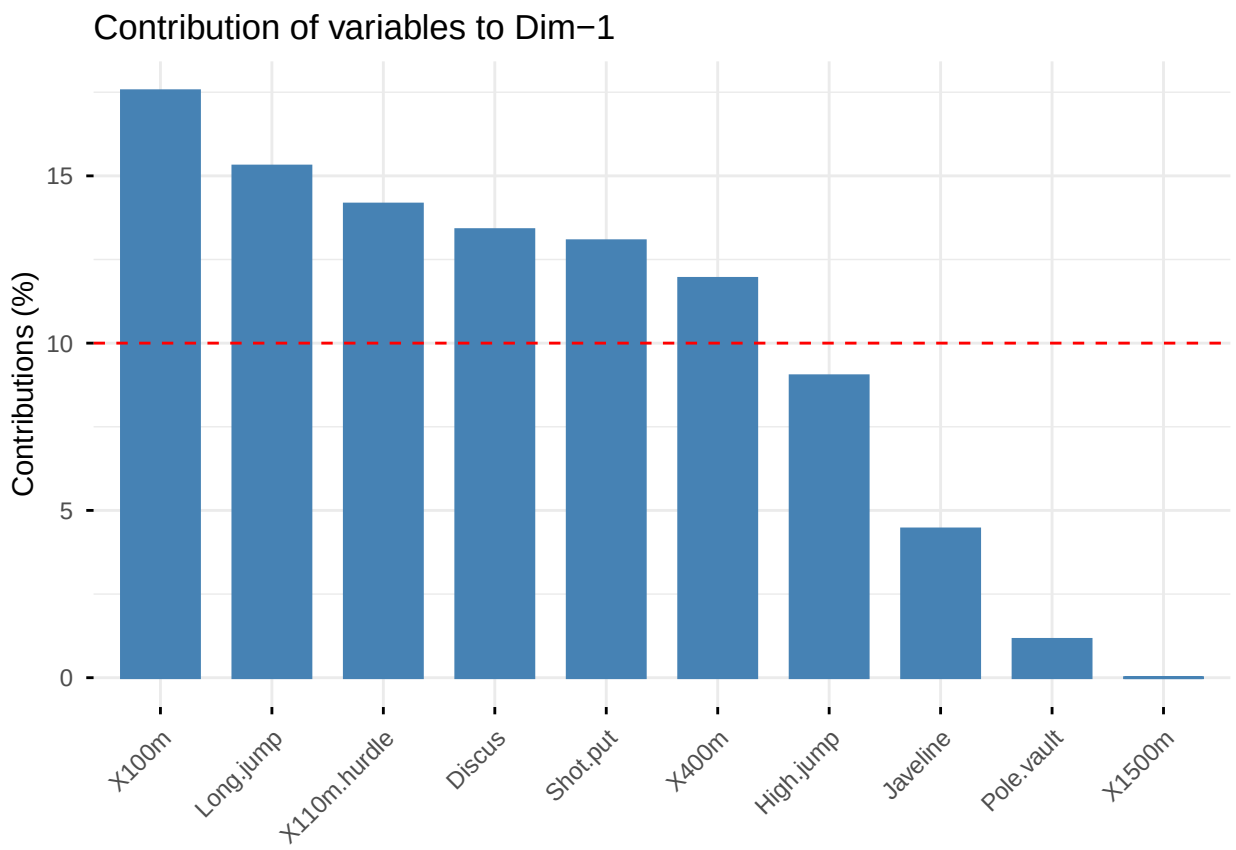
20) On met en évidence les variables qui contribuent le plus :

```
corrplot(var$contrib, is.corr = FALSE)
```

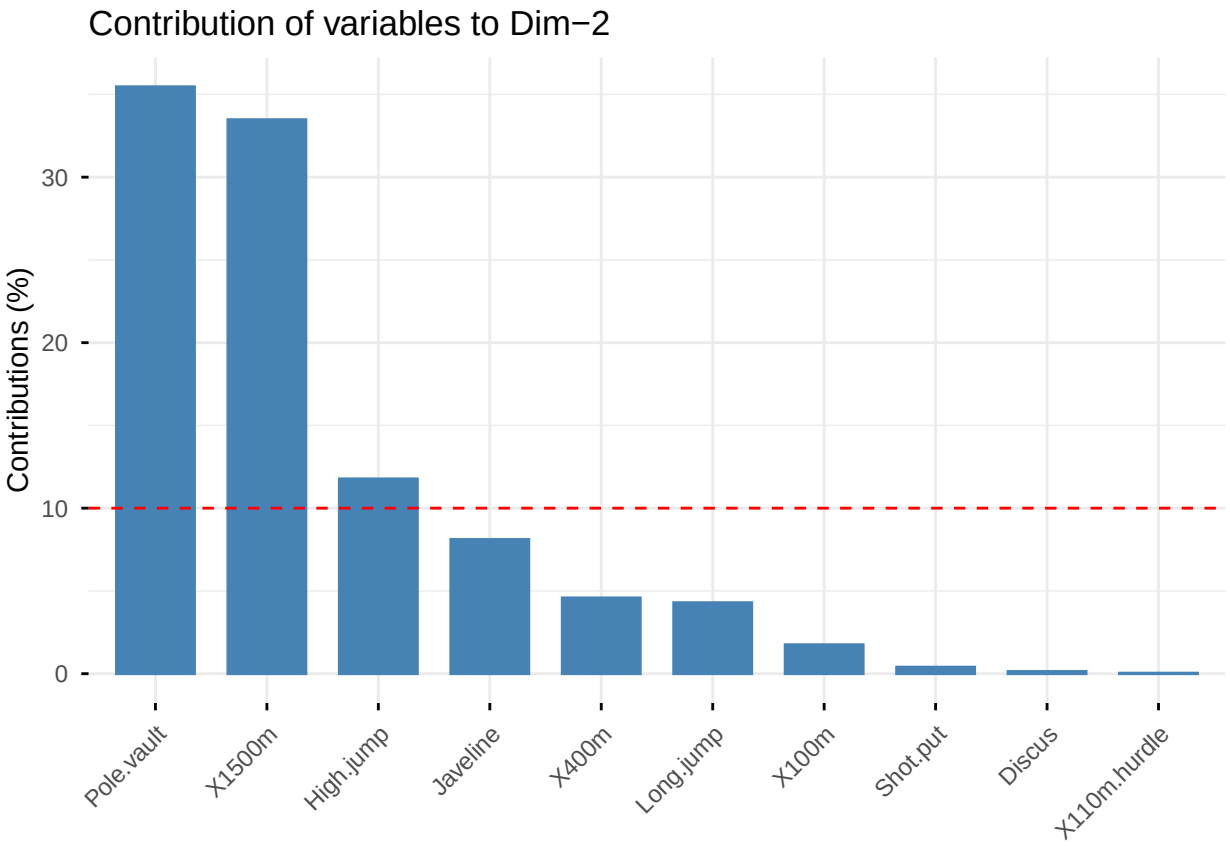


21) on trace un diagramme en barre des contributions :

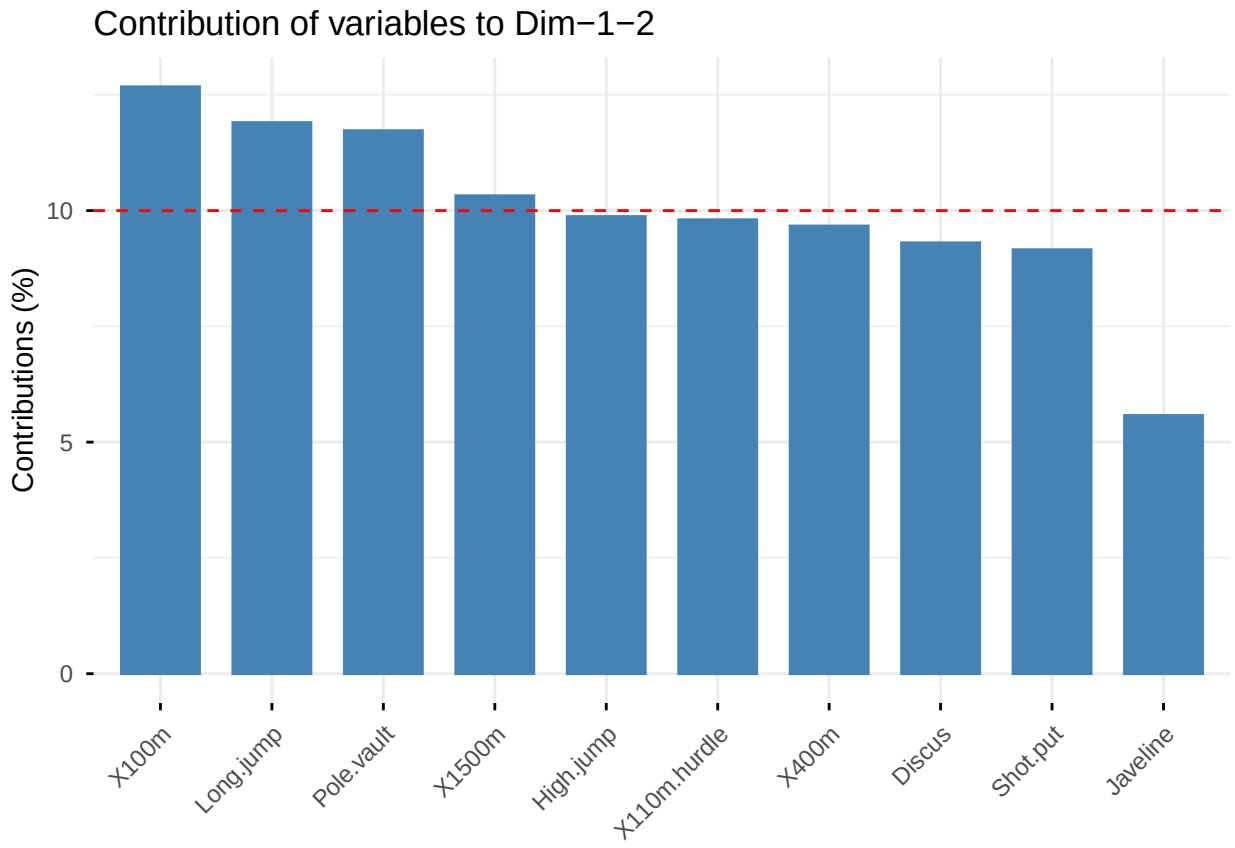
```
fviz_contrib(acpdecat, choice = "var", axes = 1)
```




```
fviz_contrib(acpdecat, choice = "var", axes = 2)
```




```
fviz_contrib(acpdecat, choice = "var", axes = 1:2)
```



G. Graphique des individus

22) On s'interesse à la foncton get_pca_ind():

```
ind <- get_pca_ind(acpdecat)
print(ind)
```

```
## Principal Component Analysis Results for individuals
##  ===================================================
##   Name       Description
## 1 "$coord"   "Coordinates for the individuals"
## 2 "$cos2"    "Cos2 for the individuals"
## 3 "$contrib" "contributions of the individuals"
```

```
head(ind$coord)
```

```
##                Dim.1      Dim.2      Dim.3       Dim.4       Dim.5
## SEBRLE     0.1955047  1.5890567  0.6424912  0.08389652  1.16829387
## CLAY       0.8078795  2.4748137 -1.3873827  1.29838232 -0.82498206
## BERNARD   -1.3591340  1.6480950  0.2005584 -1.96409420  0.08419345
## YURKOV    -0.8889532 -0.4426067  2.5295843  0.71290837  0.40782264
## ZSIVOCZKY -0.1081216 -2.0688377 -1.3342591 -0.10152796 -0.20145217
## McMULLEN   0.1212195 -1.0139102 -0.8625170  1.34164291  1.62151286
```

```
head(ind$cos2)
```

```
##                Dim.1      Dim.2       Dim.3       Dim.4        Dim.5
## SEBRLE    0.007530179 0.49747323 0.081325232 0.001386688 0.2689026575
```

```
## CLAY      0.048701249 0.45701660 0.143628117 0.125791741 0.0507850580
## BERNARD   0.197199804 0.28996555 0.004294015 0.411819183 0.0007567259
## YURKOV    0.096109800 0.02382571 0.778230322 0.061812637 0.0202279796
## ZSIVOCZKY 0.001574385 0.57641944 0.239754152 0.001388216 0.0054654972
## McMULLEN  0.002175437 0.15219499 0.110137872 0.266486530 0.3892621478
```

```
head(ind$contrib)
```

```
##                Dim.1      Dim.2      Dim.3       Dim.4       Dim.5
## SEBRLE    0.04029447  5.9714533  1.4483919  0.03734589  8.45894063
## CLAY      0.68805664 14.4839248  6.7537381  8.94458283  4.21794385
## BERNARD   1.94740183  6.4234107  0.1411345 20.46819433  0.04393073
## YURKOV    0.83308415  0.4632733 22.4517396  2.69663605  1.03075263
## ZSIVOCZKY 0.01232413 10.1217143  6.2464325  0.05469230  0.25151025
## McMULLEN  0.01549089  2.4310854  2.6102794  9.55055888 16.29493304
```

get_pca_ind() renvoie une liste avec :

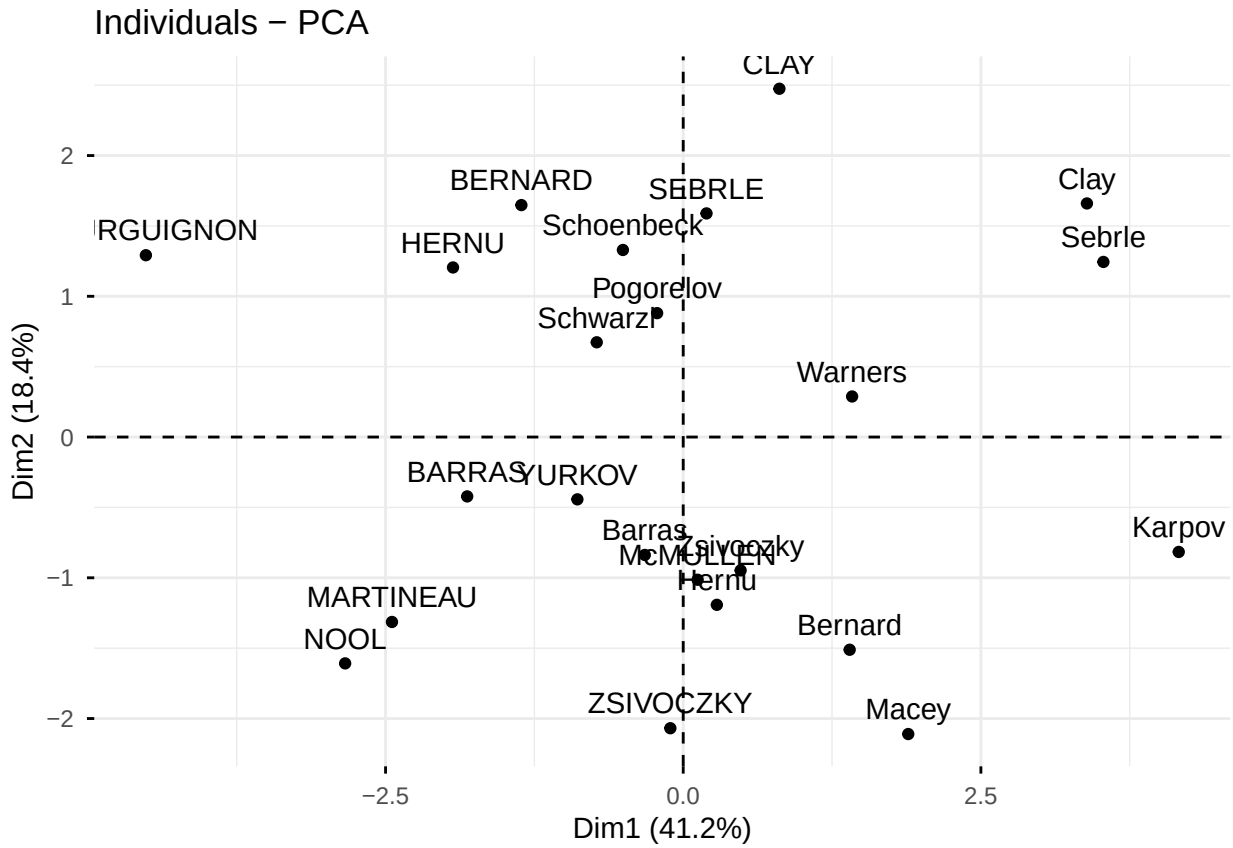
ind$coord : les coordonnées des individus sur les axes.

ind$cos2 : la qualité de représentation de chaque individu sur chaque axe.

ind$contrib : les contributions de chaque individu à la construction de chaque axe.

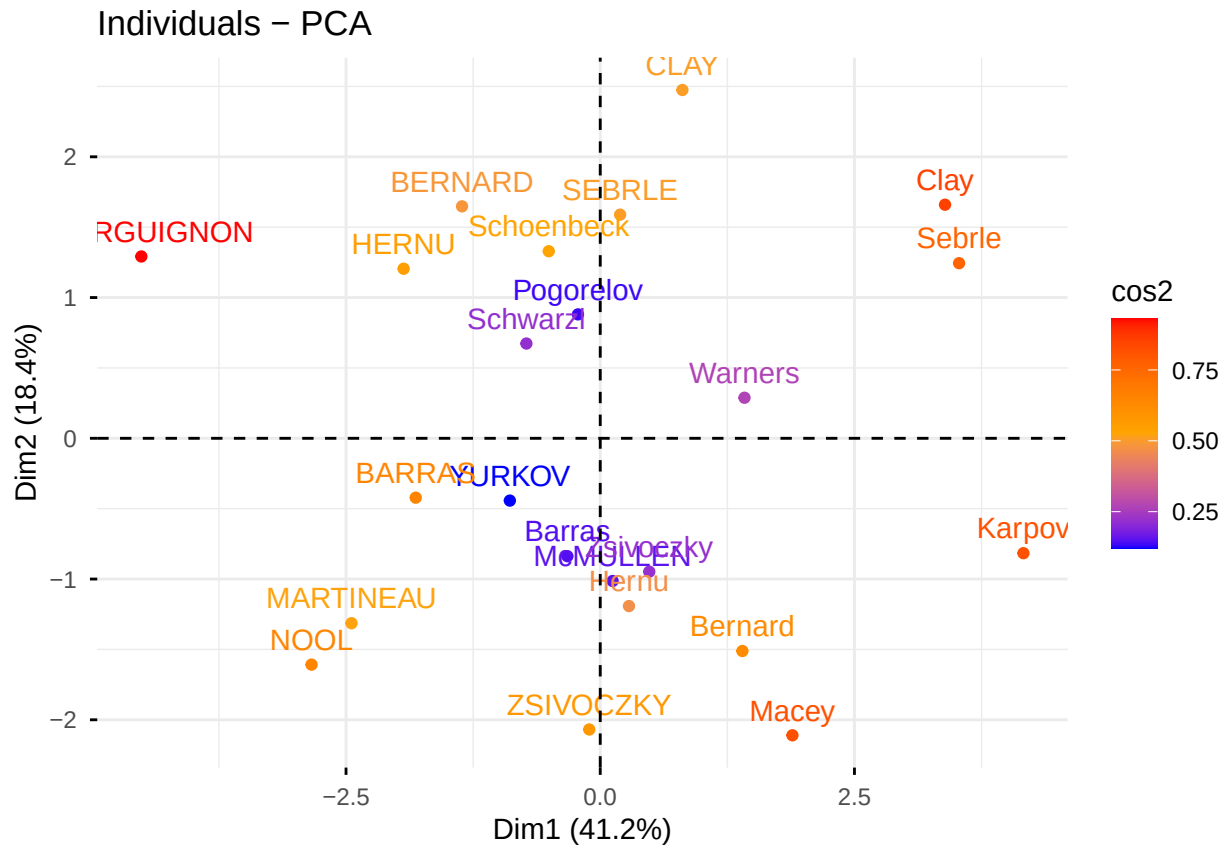
23) On produit le graphique des individus :

```
fviz_pca_ind(acpdecat)
```



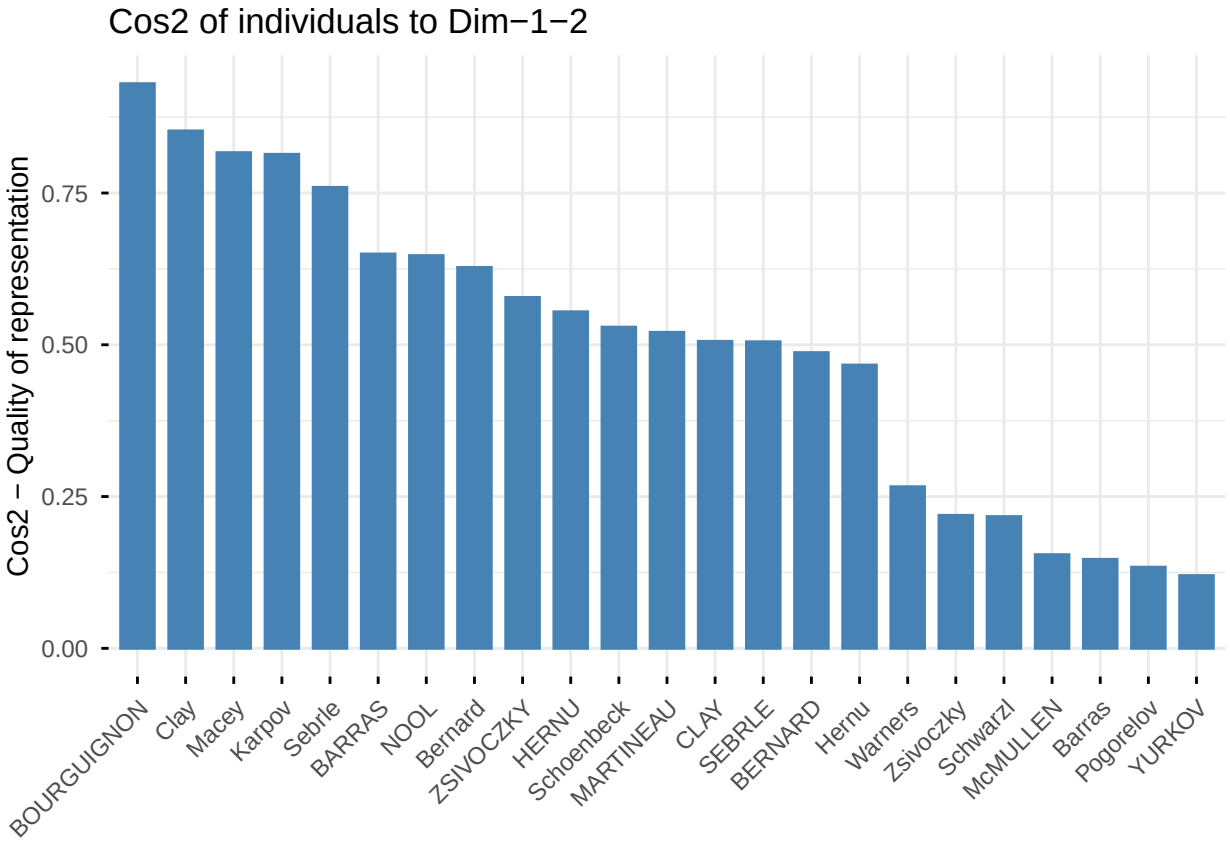
24) On améliore la visualosation :

```
fviz_pca_ind(acpdecat,
             col.ind = "cos2",
             gradient.cols = c("blue", "orange", "red"))
```



25) On fait un diagramme à barres du cos2 des individus :

```
fviz_cos2(acpdecat, choice = "ind", axes = 1:2)
```


Cos2 of individuals to Dim−1−2
Cos2 − Quality of representation
0.00
0.25
0.50
0.75
BOURGUIGNON
Clay
Macey
Karpov
Sebrle
BARRAS
NOOL
Bernard
ZSIVOCZKY
HERNU
Schoenbeck
MARTINEAU
CLAY
SEBRLE
BERNARD
Hernu
Warners
Zsivoczky
Schwarzl
McMULLEN
Barras
Pogorelov
YURKOV